


Random Forest: що це та для чого використовується?




Дерево рішень

Послідовність запитань «ознака $\leq$ поріг?», у листку — відповідь. Просте, але легко «запам'ятовує» шум.


Чому багато дерев

Кожне дерево бачить свою випадкову вибірку й випадкові ознаки, тому дерева різні, а їхні помилки взаємно гасяться.


Одне дерево
train 1.00 · test 0.86



Random Forest, 300 дерев
train 0.92 · test 0.90



Скільки дерев потрібно і як ліс голосує



Голосування для одного зразка

клас 0	48
клас 1	42
клас 2	10

Ліс обрав клас 0 — правильно, хоча 52 дерева з 100 помилились.

Де застосовують

Табличні дані: оцінка ризиків, діагностика, прогноз відтоку, виявлення аномалій. Не потребує масштабування, показує важливість ознак.

Висновок: одне дерево — 91.6 %, ліс зі 100 дерев — 98.3 % (CV). Багато різних дерев + голосування = стабільна й точна модель; після ~100 дерев росте лише час.