


Функції активації: чому в прихованих шарах ReLU




Згасання градієнта. Похідна sigmoid $\leq 0,25$, тому після 6 шарів градієнт зменшується щонайменше в 4096 разів.

Експеримент (6 шарів × 32 нейрони, SGD): градієнт 1-го шару при sigmoid $\approx 6 \cdot 10^{-6}$ проти $3 \cdot 10^{-2}$ на виході; мережа не навчилась (0,33). tanh: 0,85, ReLU: 0,83.

Вихідний шар: softmax для класифікації (ймовірності класів), лінійний вихід для регресії.

Оптимізатори: як швидко мережа зменшує помилку



Оптимізатор	Епох до асс ≥ 0,80	Ассурасу, 60 епох
SGD (крок 0,01)	не досягнуто	0,79
SGD + момент 0,9	9	0,83
RMSprop	23	0,84
Adam	21	0,84

Момент прискорює рух по пологих ділянках; RMSprop і Adam адаптують крок для кожної ваги. Adam працює зі стандартним кроком 0,001 без налаштування.

У практичній 4.8 (ReLU + softmax + Adam): класифікація ассурасу 0,90 (логістична регресія 0,79); регресія MSE 331 (лінійна регресія 1707). Якщо мережа не навчається, спершу перевіряємо активацію та оптимізатор.